



دانشکده مهندسی

گروه مهندسی برق

پایان نامه کارشناسی مهندسی برق - مخابرات

دسته بندی صداهاى قلب انسان

مبتنى بر CNN

يوسف رجب زاده

استاد راهنما

دکتر حسين ضميرى

بهمن ۱۴۰۲

چکیده

صدای قلب که نتیجه فعالیت‌های مکانیکی عضله قلب است، می‌تواند اطلاعات ارزشمندی درباره کارایی دریچه‌های قلبی ارائه دهد. ولی برای شنیدن و تفکیک این صدا با گوشی پزشکی، چالش‌های زیادی وجود دارد. از جمله محدود بودن قابلیت شنوایی انسان، عدم ثبات و پایداری صدای قلب و کم بودن انرژی صداهای ناشی از بیماری‌ها نسبت به صداهای سالم. بنابراین برای تشخیص بیماری‌ها با استفاده از صدای قلب، نیاز به تمرین و تجربه زیاد است. چون سوافل‌ها دارای اطلاعات تشخیصی زیادی در هر دو حوزه زمان و فرکانس هستند، روش‌های استخراج ویژگی‌های زمان - فرکانس بهترین روش برای پردازش این صداهای غیرطبیعی هستند. در این پژوهش، برای دسته‌بندی صداهای قلب، از ویژگی‌های حوزه زمان-فرکانس که از سیگنال‌های صدای قلب استخراج شده‌اند، استفاده کرده‌ایم. در مرحله دسته‌بندی، از چند لایه شبکه عصبی کانولوشنی بهره گرفته‌ایم و عملکرد روش پیشنهاد شده را با استفاده از تابع هزینه Categorical_Crossentropy و معیار دقت Binary_Accuracy ارزیابی کرده‌ایم. روش پیشنهاد شده را بر روی داده‌گان چالش ۲۰۱۶ فیزیونت پیاده‌سازی کرده‌ایم. نتایج نشان می‌دهند که روش پیشنهاد شده عملکرد بهتر و دقت متوسط ۹۲٪ در دسته‌بندی صداهای قلب دارد.

کلمات کلیدی

سیگنال PCG، استخراج ویژگی، CNN، دسته‌بندی، زمان - فرکانس.

سپاس‌گزاری

بر خود لازم میدانم که از زحمات و راهنمایی‌های ارزنده‌ی استاد بزرگوار، جناب آقای دکتر ضمیری جعفریان در
به سرانجام رسیدن این پایان‌نامه تشکر و قدردانی نمایم.

۱ فصل اول : پیشگفتار	۱
۱-۱ مقدمه	۱
۲-۱ اهداف تحقیق	۳
۳-۱ ساختار پایان نامه	۳
۲ فصل دوم : پیشینه پژوهش	۴
۱-۲ MEL-FREQUENCY SPECTROGRAM	۷
۲-۲ ALEXNET AND WAVENET	۸
۳ فصل سوم : پایگاه‌های داده	۱۱
۱-۳ صدای قلب میشیگان (OMHSML)	۱۲
۲-۳ چالش پاسکال ۲۰۱۱ (CHSC2011)	۱۲
۳-۳ مجموعه پادکست صدای‌های قلب تگزاس (THI)	۱۲
۴-۳ چالش فیزیونت ۲۰۱۶	۱۳
۴ فصل چهارم : الگوریتم پیشنهادی جهت دسته‌بندی سیگنال PCG	۱۵
۱-۴ تحلیل زمان - فرکانس سیگنال‌های غیرایستاد	۱۵
۲-۴ ویژگی‌های زمان - فرکانس	۱۷
۳-۴ پیش‌پردازش	۱۹
۴-۴ ساختن و آموزش مدل CNN	۲۳
۵-۴ ارزیابی عملکرد مدل	۲۴
۵ فصل پنجم : جمع‌بندی و نتیجه‌گیری	۲۶
۶ مراجع	۲۸

فهرست جداول

جدول ۱-۲ : مروری بر مطالعات برجسته در زمینه تحلیل سیگنال‌های PCG

جدول ۱-۳ : پرستفاده‌ترین دیتاست‌های PCG

جدول ۲-۳ : جزئیات مجموعه‌های آزمون و آموزش پایگاه داده [۳۹, ۳۲]

جدول ۱-۴ : برخی از RI-TFDS و کرنل آنها در حوزه زمان- تأخیر [۳۳]

فهرست اشکال

شکل ۱-۱ : سیگنال PCG^3 و صداهای قلب

شکل ۱-۴ : نمایش انرژی و اسپکتروگرام یک فایل صوتی ($a0007$)

شکل ۲-۴ : نمایش ۹ نمونه از اسپکتروگرام ها به صورت تصادفی (پس از انجام *data_augmentation*)

شکل ۳-۴ : شمای کلی از مدل استفاده شده به جهت دسته‌بندی

شکل ۴-۴ : ماتریس درهم ریختگی داده‌های تست

فهرست اختصارات

- ¹ Systole
- ² Diastole
- ³ Phonocardiogram
- ⁴ Cross-Wavelet Transform
- ⁵ Support Vector Machine
- ⁶ Deep Neural Network
- ⁷ Electrocardiogram
- ⁸ Hidden Markov Model
- ⁹ Artificial Neural Network
- ¹⁰ K-Nearest Neighbors
- ¹¹ Convolutional Neural Network
- ¹² Long Short-Term Memory
- ¹³ Quadratic Time–Frequency Distributions
- ¹⁴ Fast Fourier Transform
- ¹⁵ Time–Frequency Distributions
- ¹⁶ Reduced interference TFD
- ¹⁷ Wigner Ville Distribution
- ¹⁸ Smoothed Wigner-Ville Distribution
- ¹⁹ Choi–Williams distribution
- ²⁰ Spectrogram
- ²¹ Modified B-Distribution
- ²² Extended Modified B-Distribution
- ²³ Singular Value Decomposition

فصل اول

پیشگفتار

۱-۱ مقدمه


بیماری‌های قلبی و عروقی در سراسر جهان از عوامل اصلی مرگ و میر انسان‌ها هستند. آمار منتشر شده توسط سازمان جهانی بهداشت در سال ۲۰۰۵ نشان می‌دهد که هر سال حدود ۱۷.۵ میلیون نفر در دنیا به خاطر این بیماری‌ها فوت می‌کنند. این عدد ۳۰ درصد از کل مرگ و میرهای جهان را شامل می‌شود و پروژه‌های آماری پیش بینی می‌کنند که تا سال ۲۰۳۰ تعداد فوت‌شدگان به دلیل بیماری‌های قلبی به ۲۳.۶ میلیون نفر برسد [۱].

گوش کردن به صداهای قلب از روش‌های قدیمی پزشکی است که پزشکان از زمان‌های دور از آن استفاده می‌کرده‌اند. صداهای قلب از حرکات مکانیکی قلب ناشی می‌شوند. این حرکات امواج صوتی با فرکانس پایین را ایجاد می‌کنند. این روش برای غربالگری، تشخیص و درمان اولیه مناسب است چون روش غیرتهاجمی، کم‌هزینه، آسان و قابل اطمینان است. همچنین با استفاده از این روش، می‌توان اطلاعات مفید درباره عملکرد قلب به دست آورد و ناهنجاری‌ها و اختلالات قلب را تعیین کرد. شناسایی صحیح صداهای قلب و تحلیل عملکرد آن یک مهارت بسیار دشوار است که فقط پزشکان با تجربه چند ساله می‌توانند با استفاده از آن، صداهای سالم و بیمار را تفکیک کنند. دلایل اصلی این مسئله در زمان کوتاه صداهای قلب و تلاقی آن‌ها با صداهای تنفس در ریه است [۲].

دسته‌بندی خودکار سیگنال صدای قلب با استفاده از سامانه‌های کامپیوتر و نرم‌افزارهای تحلیلی می‌تواند دقت و صحت تشخیص را به شکل قابل توجهی بالا برده و همچنین مراجعه مکرر بیمار به مراکز درمانی را کاهش دهد. بنابراین، ارائه روشی برای تشخیص خودکار ناهنجاری‌های قلبی با تحلیل صداهای قلبی ضبط شده توسط گوشی پزشکی می‌تواند بسیار کارآمد باشد. با توجه به اهمیت و ضرورت این موضوع، توسعه الگوریتم‌هایی برای دسته‌بندی صدای قلب در تشخیص بیماری‌های قلبی به عنوان چالش ۲۰۱۶ فیزیونت مطرح شده است [۲۶]. در سال‌های اخیر نیز پژوهشگران و محققان در جهان روش‌های مختلفی را برای تشخیص هوشمند و دقیق بیماری‌های قلبی پیاده سازی کرده‌اند [۲۶].

برای شنیدن صداهای قلب، معمولاً از گوشی‌های طبی یا دستگاه فونوکاردیوگراف که صدا را ضبط می‌کند، استفاده می‌شود. فونوکاردیوگراف، دستگاهی است که صدا را بر اساس تغییرات صوتی در قفسه سینه که به خاطر جریان خون در قلب ایجاد می‌شود، ثبت می‌کند. خروجی این دستگاه، حاوی اطلاعات مفید درباره وضعیت جریان

خون است و امکان تشخیص برخی از بیماری‌های قلب و عروق و مشکلات مربوط به آن را فراهم می‌کند. صداهای قلب که از طریق این دستگاه شنیده می‌شوند، به دو بخش اصلی صدای اول (S1) و صدای دوم (S2) تقسیم می‌شوند. هر صدای دیگر که در کنار این دو صدا باشد، به عنوان صدای غیرطبیعی قلب شناسایی می‌شود که برای تشخیص بیماری‌های قلبی مناسب هستند. بسیاری از پزشکان، فونوکاردیوگراف را یک ابزار مفید برای شناسایی حالات غیرطبیعی قلب میدانند؛ چرا که نه تنها اطلاعات کلینیکال مهم را در اختیار پزشک قرار می‌دهد، بلکه استفاده از آن ساده، ارزان و کارآمد است. [۲۷] صداهای قلب، نتیجه فعالیت‌های مکانیکال قلب هستند که با پالس‌های الکتریکی که در گره سینوسال - دهلیز تولید می‌شوند، همراه هستند. پالس‌های الکتریکی باعث میشوند عضلات قلب فعال شده و جریان خون را در دهلیزها و بطن‌ها تغییر می‌دهند. با تغییر جریان خون، صدای قلب نیز در فواصل مختلف تغییر می‌کند و منشأ هر یک را می‌توان به باز یا بسته شده دریچه‌های قلبی ربط داد. به این ترتیب، ۴ صدای مختلف را می‌توان از قلب شنید که با نام‌های صدای اول سیستول¹ (S₁), فاصله بین صدای اول تا دوم، صدای دوم دیاستول² (S₂), فاصله بین صدای دوم تا اول بعدی، مشخص شده‌اند. همچنین، فعالیت‌های مکانیکی قلب ممکن است صداهای دیگری را نیز ایجاد کنند مانند صدای سوم قلب (S₃) و صدای چهارم قلب (S₄) که به عنوان صداهای ضعیف قلبی شناخته می‌شوند. در شکل ۱-۱ این صداها و فاصله‌های آنها نشان داده شده‌اند [۲۸].



شکل ۱-۱: سیگنال PCG³ و صداهای قلب

۲-۱ اهداف تحقیق

در چند دهه اخیر، تحقیقات زیادی در زمینه تحلیل سیگنال صدای قلب (PCG) برای تشخیص اتوماتیک بیماری‌های قلبی صورت گرفته است. این تحقیقات ارزشمند هستند، اما بیشتر روی بخش‌بندی سیگنال صوتی، حذف نویز و آنالیز طیفی قسمت‌های مختلف سیگنال PCG شامل صدای اول و دوم قلب و در نهایت، دسته‌بندی بیماری‌های قلبی با روش‌های اتوماتیک متمرکز شده‌اند، که هنوز به مرحله کاربرد کلینیکی نرسیده‌اند. یکی از علل مهم این وضعیت، عدم داشتن شناخت و دانش کافی از ساختارهای ذاتی و رفتارهای بنیادین سیگنال PCG است. به بیان دیگر، کارهای کمی برای شناسایی ساختار اجزای مختلف سیگنال و استخراج ویژگی‌هایی که نشأت گرفته از ماهیت سیگنال هستند انجام شده است به همین خاطر این مسئله به‌عنوان موضوع چالش ۲۰۱۶ فیزیونت انتخاب شده است که روش بهینه‌ی ارائه شده برای دسته‌بندی صدای قلب در این چالش به میانگین حساسیت و اختصاصیت ۸۶٪ روی داده‌های دیده نشده توسط مدل رسیده است [۳۶]. روش ارائه شده در این پایان نامه، با توجه به ماهیت غیرثابت سیگنال صدای قلب، تمرکز بر تحلیل سیگنال‌های PCG در حوزه زمان - فرکانسی و استخراج ویژگی‌های حوزه زمان - فرکانسی از این سیگنال‌ها برای تشخیص اتوماتیک ناهنجاری‌های قلبی پایه است. کارایی این ویژگی‌ها در دسته‌بندی سیگنال‌های غیرایستاد به‌طور کلی و سیگنال‌های بیولوژیکی به‌طور خاص، در تحقیقات قبلی نشان داده شده است [۴۴، ۳۳-۳۵].

۳-۱ ساختار پایان نامه

پیشینه پژوهش در فصل دوم و پایگاه‌های داده معروف PCG در فصل سوم ارائه خواهند شد. الگوریتم پیشنهادی جهت دسته‌بندی خودکار صداهاى ضبط شده قلب و نتایج آن در فصل چهارم معرفی می‌گردد. و فصل پنجم شامل جمع‌بندی و نتیجه‌گیری است.

فصل دوم

پیشینه پژوهش

یک بررسی از مطالعات برجسته در زمینه تحلیل سیگنال‌های PCG در جدول ۲-۱ ارائه شده است. تحلیل این روش‌ها نشان می‌دهد که پردازش سیگنال، یادگیری ماشین و یادگیری عمیق سه رویکرد اصلی مورد بررسی برای طبقه‌بندی سیگنال‌های PCG هستند. از بین این روش‌ها، یادگیری عمیق به عنوان یک راه‌حل جذاب در سال‌های اخیر به چشم می‌خورد و عملکردی قابل قبول را گزارش کرده است. جدول ۲-۱ همچنین نشان می‌دهد که هم داده‌های عمومی و هم خصوصی در مطالعات مختلف استفاده شده‌اند. داده‌های عمومی رایج شامل PASCAL-11 [۴۱]، MHSML-2014 [۴۲]، PhysioNet-2016 [۳۸] و Yaseen-2018 [۳۱] هستند. سیگنال‌ها به طور کلی به دو دسته گسترده یعنی نرمال و غیرنرمال تقسیم می‌شوند. علاوه بر این، سیگنال‌های غیرنرمال بر اساس نوع بیماری و سایر عوامل دسته‌بندی می‌شوند. مرحله پیش‌پردازش، به طور کلی، شامل فیلترینگ و کاهش نمونه برای روش‌های مبتنی بر پردازش سیگنال است. اما برای روش‌های مبتنی بر یادگیری ماشین، تکنیک‌های پیشرفته‌ای مانند تبدیل موجک متقاطع (CWT^4) استفاده شده‌اند. طبقه‌بندی با استفاده از اصول هیورستیکی مانند مکان‌های S1، S2 و غیره یا روش‌های نظارت شده مانند SVM⁵ یا DNN⁶ انجام می‌شود. طبقه‌بندی (دودویی یا چندکلاسه) در سطح سیگنال یا چرخه در مطالعات مختلف گزارش شده است. [۳۰]

به لطف دسترسی آسان به منابع محاسباتی، تجزیه و تحلیل خودکار سیگنال‌های PCG به عنوان یک مسئله تحقیقاتی رایج در جامعه پردازش سیگنال ظاهر شده است. در یکی از تلاش‌های قبلی برای تحلیل سیگنال‌های PCG، Ricke و همکارانش [۳] سیگنال‌های PCG را با استفاده از سیگنال‌های ECG⁷ به عنوان مرجع و با استفاده از مدل پنهان مارکوف (HMM^8) تقسیم بندی کردند. در طول مدل‌سازی، سیگنال‌ها با استفاده از فیلتر میان‌گذر و محاسبه میانگین پوش انرژی شانون (Shannon Energy Envelope) پیش‌پردازش شدند. پوش انرژی شانون، طیف متوسط انرژی است که در قطبیت‌های مختلف QRS و تغییرات ناگهانی در دامنه QRS، بهتر می‌تواند پیک‌ها را تشخیص دهد. متعاقباً از فیلترهای Mel-Spaced برای تولید ضرایب رگرسیون استفاده می‌شود که منجر به ویژگی‌های طیفی در محدوده فرکانس بین ۱۰ تا ۳۴۰ هرتز می‌شود. در نهایت، HMM به مدلی اعمال می‌شود که متعاقباً صداهای PCG را تقسیم می‌کند. در حالی که Ricke و همکاران [۳] از سیگنال ECG برای تقسیم بندی استفاده می‌کنند، مطالعات به طور کلی بر تقسیم بندی و همچنین طبقه بندی سیگنال‌های PCG با استفاده از اطلاعات محلی از خود سیگنال متمرکز است. در یکی از این آثار، اولیویرا و همکاران [۴] سیگنال‌های PCG را با استفاده از آنتروپی (اندازه گیری توزیع توان طیفی) و Envelopogram (یک نمودار ریاضی ساخته شده از

پوش سیگنال فونوکاردیوگرام) تقسیم کردند. در یک مطالعه نسبتاً جدید، پاراساد و همکاران. [۵] سیگنال را با استفاده از فیلتر فرکانس صفر (Zero Frequency Filter) به مکان های S1 و S2 تقسیم کردند.

جدول ۱-۲ : مروری بر مطالعات برجسته در زمینه تحلیل سیگنال های PCG

Study	Dataset	Signals/Cycles	Signal types	Pre-processing	Classifier	Analysis level	Performance
Bourouhou et al. [14], 2022	PASCAL A and B, 2011	621	Bandpass filtering	kNN, SVM etc	-	Multi-class	Total precision (3.06)%
OH et al. [18], 2021	Yaseen, 2018	1000	Multi-class	Normalization	WaveNet	Multi-class	98.2%
Touahria et al. [6], 2021	PASCAL A and B, 2011	621	Raw	HMM	Cardiac cycle	Binary	92.74%
Ajitkumar Singh et al. [13], 2021	PhysioNet, 2016	409	Normal and Abnormal	Filtering	kNN, SVM, and Ensemble	Binary	93.14%
Dhar et al. [19], 2021	PhysioNet, 2016	3240	Normal and Abnormal	Cross-Wavelet Transform	AlexNet	Multi-class	98%
Prasad et al. [5], 2020	PASCAL A and B, 2011	621	-	ZFF	S1, S2 locations	-	99%
Li et al. [22], 2020	PhysioNet, 2016	3240	Normal and Abnormal	STFT	CNN	Binary	85%
Gjoreski et al. [23], 2020	Private, 2016/ PhysioNet, 2016	3386	Normal and Chronic heart failure(CHF)	Spectrogram	ML and End-to-End learning	Multi-class	86.3%
Chowdhury et al. [17], 2020	MHSML, 2014 and PhysioNet, 2016	3260	Denoising and compression	MFCC	DNN	Binary	97.1%
He et al. [16], 2020	PhysioNet, 2016	792	Normal and Abnormal	Normalization	DNN	Binary	99.7%
Baccouche et al. [15], 2020	Private	800	Normal & CVD	Raw	CNN-LSTM	Binary	96%
Noman et al. [24], 2019	Physionet, 2016	3153	Bandpass filtering	Viterbi and Kalman filters	-	Binary	82.40%
Jorge et al. [4], 2014	PASCAL, 2011	90	Filtering and decimation	-	S1 and S2 locations	-	98.7%
Mandeep & Amandeep [11], 2013	PASCAL, 2011	60	Normal and Murmur	-	Bayes Nets	Binary	93.3%
Fatemeh et al. [25], 2012	Private	350	Normal and Murmur	Resampling and filtering	BayesNet	Binary	96.94%
Samit & Goutam [8], 2009	Private	12	Normal & CVD	Filtering & Normalization	ANN	Binary	99.3%
Abbas et al. [7], 2008	Private	14	Normal & Murmur	Filtering and normalization	Thresholding	Binary	P-value (93.2%)
Ricke et al. [3], 2005	Cardio Lab Data	46	Normal	Bandpass filtering	HMM	Binary	Frame & Model error (0.16 ± 0.19)

به طور کلی، تقسیم بندی برای طبقه بندی سیگنال های PCG برای تشخیص بیماری انجام می شود. توهیرا و همکاران [۶]، برای مثال، سیگنال های قلب را با استفاده از HMM مدل سازی کردند تا سیگنال ها را به عنوان نرمال یا غیرنرمال طبقه بندی کند. در پژوهشی مشابه، عباس و همکاران. [۷] طبقه بندی باینری را انجام دادند و گوتام [۸] در کار مشابه سیگنال های CVD (Cardiovascular Disease) را از سیگنال های نرمال با استفاده از یک شبکه عصبی مصنوعی (ANN^9) متمایز کرد. نویسندگان قبل از استخراج ویژگی هایی که به یک شبکه عصبی مصنوعی تغذیه می شوند، از فیلتر کردن و نرمالایز کردن استفاده کردند. این رویکرد منجر به نرخ طبقه بندی بالای ۹۹.۳٪ شد. در مطالعه دیگری، Grzegorzcyk و همکاران. [۹] همچنین از ANN برای طبقه بندی سیگنال استفاده کردند. با این حال، مطالعه آنها محدود به طبقه بندی سیگنال ها به عنوان نرمال و غیرنرمال بود. به همین ترتیب، شبکه های بیزین برای طبقه بندی سیگنال های PCG در مطالعاتی مانند [۱۰، ۱۱] مورد بررسی قرار گرفته اند.

یکی دیگر از گزینه های محبوب برای طبقه بندی سیگنال های PCG، ماشین بردار پشتیبانی (SVM) است. از میان مطالعاتی که از طبقه بندی کننده SVM استفاده می کنند، Tange و همکارانش. [۱۲] SVM را با ویژگی های چند حوزه ای (Multi-Domain) ترکیب کردند. ویژگی ها از حوزه های زمان، فرکانس و زمان-فرکانس استخراج شده و دقت ۸۸ درصد گزارش شده است. به طور مشابه، سینگ و همکاران. [۱۳] طبقه بندی کننده های متعدد (SVM، KNN، و Ensembles) را برای طبقه بندی سیگنال های PCG بررسی می کنند. در یکی از مطالعات نسبتاً اخیر، Bourouhou et al. [۱۴] از KNN^{10} و SVM برای طبقه بندی چند کلاسه استفاده می کنند.

در سال های اخیر، یک تغییر الگو از یادگیری ماشینی معمولی به روش های مبتنی بر یادگیری عمیق صورت گرفته است. در حالی که تکنیک های یادگیری ماشینی سنتی بر حوزه دانش استخراج ویژگی های (دست ساخته) تکیه می کنند، یادگیری عمیق بر یادگیری ویژگی مبتنی بر داده استوار است. در میان تکنیک های مختلف یادگیری عمیق، شبکه های عصبی کانولوشنال (CNN^{11}) بیشتر مورد استفاده قرار گرفته اند. از میان مطالعات قابل توجه، باکوش و همکاران. [۱۵] از ترکیبی از شبکه های عصبی کانولوشنی و مکرر برای انجام طبقه بندی باینری سیگنال ها به عنوان نرمال یا غیرنرمال بهره برداری می کنند. نویسندگان استدلال می کنند که داده های صدای قلب، که ماهیت چرخه ایستایی دارند، می توانند به عنوان یک دنباله مدل سازی شوند. این تکنیک ابتدا توالی های ویژگی را با استفاده از لایه های کانولوشن و سپس مدل سازی توالی و طبقه بندی با استفاده از $LSTM^{12}$ استخراج می کند. در میان سایر مطالعات، He و همکاران. [۱۶] و Chowdhary و همکاران. [۱۷]، همچنین از شبکه های عصبی عمیق برای تجزیه و تحلیل سیگنال استفاده کردند. He [۱۶] از AdaBoost (یک متالگوریتم طبقه بندی آماری) و CNN برای طبقه بندی بر روی سیگنال های تقسیم بندی شده استفاده می کند در حالی که Chowdhary و همکاران. [۱۷] سیستم نسبتاً پیچیده تری را پیشنهاد می کنند که در آن از Mel-Spectrogram برای یادگیری استفاده می شود.

مل-اسپکتروگرام، که به عنوان مل-فرکانس اسپکتروگرام نیز شناخته می‌شود، روشی برای مجسم سازی محتوای فرکانس یک سیگنال صوتی در طول زمان است. این از یک اسپکتروگرام عادی استخراج می‌شود که فرکانس‌های موجود در یک سیگنال صوتی را به عنوان یک تابع از زمان نمایش می‌دهد. با این حال، مل-اسپکتروگرام یک مقیاس ادراکی به نام مقیاس مل را برای تطابق بهتر با ادراک سیستم شنوایی انسان ادغام می‌کند.

مقیاس مل یک مقیاس غیرخطی است که محدوده فرکانس شنوایی انسان را به یک فضای ادراکی یکنواخت‌تر نگاشت می‌کند. این به این معنی است که تفاوت‌های کوچک‌تر در فرکانس توسط تفاوت‌های کوچک‌تر در مقیاس مل نمایش داده می‌شوند، که با چگونگی ادراک گوش‌های ما از صدا تطابق بهتری دارد. با اعمال مقیاس مل به اسپکتروگرام، مل-اسپکتروگرام نتیجه یک نمایش دقیق‌تر از سیگنال صوتی از لحاظ چگونگی ادراک انسان از فرکانس‌های مختلف را فراهم می‌کند.

تفاوت اصلی بین یک اسپکتروگرام عادی و یک مل-اسپکتروگرام در محور فرکانس قرار دارد. در یک اسپکتروگرام عادی، محور فرکانس خطی و به طور مساوی فاصله گذاشته شده است. این به این معنی است که هر بین فرکانس به طور مساوی فاصله گذاشته شده است، بدون توجه به حساسیت سیستم شنوایی انسان به فرکانس‌های مختلف. در مقابل، یک مل-اسپکتروگرام از مقیاس مل برای کشیدن یا فشردن محور فرکانس استفاده می‌کند، موجب ایجاد یک مقیاس غیرخطی می‌شود که در آن بین‌های فرکانس در مناطقی که گوش انسان حساس‌تر است، فاصله‌های نزدیک‌تری دارند.

در نتیجه، یک مل-اسپکتروگرام نسخه اصلاح شده‌ای از یک اسپکتروگرام است که مقیاس مل را برای تطابق بهتر با روشی که انسان‌ها صدا را ادراک می‌کنند، ادغام می‌کند. با استفاده از مقیاس مل، مل-اسپکتروگرام یک نمایش دقیق‌تر و ادراکی مرتبط‌تر از محتوای فرکانس در یک سیگنال صوتی را فراهم می‌کند. این آن را یک ابزار ارزشمند در زمینه‌های مختلفی مانند پردازش سخن، تجزیه و تحلیل موسیقی، و پردازش سیگنال صوتی می‌کند.

استفاده از شبکه های عصبی عمیق از قبل آموزش دیده و تطبیق آنها با مشکل موجود (یادگیری انتقالی)، رویکرد دیگری است که در میان تحقیقات در زمینه پردازش سیگنال و همچنین حوزه های یادگیری ماشین محبوبیت قابل توجهی به دست آورده است. در حالی که یادگیری انتقالی در وظایف بینایی کامپیوتری مانند تشخیص اشیاء بسیار رایج است، برای مشکلات مبتنی بر پردازش سیگنال نسبتاً کمتر مورد بررسی قرار می گیرد. با این حال، روندهای اخیر نشان می دهد که این رویکرد توجه پژوهشی جامعه پردازش سیگنال را به خود جلب کرده است [۱۸، ۱۹]. به عنوان مثال، AlexNet [۲۰] و WaveNet [۲۱] برای طبقه بندی ضربان قلب به کار گرفته شده اند.

۲-۲ AlexNet and WaveNet

AlexNet و WaveNet هر دو مدل های یادگیری عمیق هستند که در حوزه های مربوط به خودشان سهم قابل توجهی داشته اند.

AlexNet، که توسط Alex Krizhevsky و همکارانش توسعه یافت، با برنده شدن در چالش تشخیص بصری مقیاس بزرگ ImageNet در سال ۲۰۱۲، حوزه بینایی کامپیوتر را انقلابی کرد. این یکی از اولین شبکه های عصبی کانوولوشنی عمیق (CNN) بود که توانست عملکرد برتر در وظایف طبقه بندی تصویر مقیاس بزرگ را به دست آورد.

AlexNet با معماری عمیق خود که شامل چندین لایه کانوولوشنی، لایه های pooling و لایه های fully connected است، متمایز می شود. این تکنیک هایی مانند ReLU activation، تنظیم dropout و data augmentation را معرفی کرد که توانایی مدل در یادگیری نمایش های سلسله مراتبی از تصاویر را به طور قابل توجهی افزایش داد.

۱. لایه های کانولوشن: لایه های کانولوشن مسئول استخراج ویژگی های فضایی (spatial) از داده های ورودی هستند. این لایه ها شامل چندین فیلتر هستند که عملیات کانولوشن را روی داده های ورودی انجام می دهند و نقشه های ویژگی را تولید می کنند. این نقشه های ویژگی الگوها و نمایش های مختلف از داده های ورودی را فرامی گیرند، امکان یادگیری ویژگی های سلسله مراتبی را برای مدل فراهم می کنند.

۲. لایه های پولینگ: لایه های پولینگ برای کاهش ابعاد فضایی نقشه های ویژگی که توسط لایه های کانولوشن تولید شده اند، استفاده می شوند. آنها نقشه های ویژگی را با تقسیم کردن آنها به مناطق غیر همپوشان و انتخاب یک مقدار نماینده (به عنوان مثال، حداکثر یا میانگین) از هر منطقه، کاهش می دهند. این کمک می کند تا پیچیدگی محاسباتی مدل را کاهش دهد و همچنین در استخراج ویژگی های مربوطه کمک می کند.

۳. لایه‌های fully connected: لایه‌های fully connected مسئول وظایف استدلال و طبقه‌بندی سطح بالا هستند. آن‌ها نقشه‌های ویژگی تخت شده را از لایه‌های کانولوشن و پولینگ می‌گیرند و هر نورون را به هر نورون در لایه بعدی متصل می‌کنند. این لایه‌ها به مدل امکان یادگیری روابط پیچیده بین ویژگی‌ها را می‌دهند و بر اساس آن‌ها پیش‌بینی می‌کنند.

۴. ReLU activation: تابع فعال‌سازی (Rectified Linear Unit) ReLU غیرخطی بودن را به مدل CNN می‌افزاید. این تابع به صورت عنصر به عنصر به خروجی لایه‌های کانولوشن و fully connected اعمال می‌شود. ReLU هر مقدار منفی را به صفر تنظیم می‌کند و مقادیر مثبت را بدون تغییر نگه می‌دارد. این تابع فعال‌سازی به مدل کمک می‌کند تا روابط غیرخطی را یاد بگیرد و مدل را بیانگر تر می‌کند.

۵. Dropout: Dropout یک تکنیک نظم‌دهی است که برای جلوگیری از بیش‌برازش در مدل CNN استفاده می‌شود. این تکنیک به صورت تصادفی یک بخش از واحدهای ورودی را در طول آموزش به صفر تنظیم می‌کند. این مانع می‌شود که مدل بیش از حد بر روی نورون‌های خاصی تکیه کند و اجبار می‌کند که ویژگی‌های بیشتری را یاد بگیرد. حذف تصادفی عملکرد مدل را بهبود می‌بخشد و احتمال بیش‌برازش را کاهش می‌دهد.

۶. Data augmentation: افزایش داده یک تکنیک است که برای افزایش به صورت مصنوعی اندازه و تنوع مجموعه آموزش استفاده می‌شود. این شامل اعمال تبدیلات مختلف، مانند مقیاس‌بندی، چرخش، برگرداندن یا برش، به داده‌های ورودی است. افزایش داده کمک می‌کند در کاهش بیش‌برازش، بهبود توانایی عمومی مدل، و بیشتر مقاوم ساختن آن در برابر تغییرات در داده‌های ورودی.

از سوی دیگر، WaveNet که توسط DeepMind توسعه یافت، بر وظایف تولید صدا و مولد سخن متمرکز است. این در سال ۲۰۱۶ معرفی شد و بر اساس یک مدل مولد عمیق به نام شبکه عصبی خودبازگشتی WaveNet است. WaveNet از کانولوشن‌های dilated استفاده می‌کند، که به آن امکان می‌دهد تا یک زمینه دریافتی به طور نمایی بزرگ داشته باشد و وابستگی‌های بلندمدت در دنباله‌های صوتی را فراگیرند. این مدل با موفقیت در وظایفی مانند سنتز متن به سخن و تولید موسیقی استفاده شده است و خروجی‌های با کیفیت بالا و صدای طبیعی تولید می‌کند.

با وجود تفاوت‌هایشان در حوزه‌های کاربرد، هر دو AlexNet و WaveNet نقش محوری در پیشرفت یادگیری عمیق ایفا کرده‌اند. AlexNet محبوبیت و اثربخشی CNN ها در بینایی کامپیوتر را تقویت کرد، منجر به پیشرفت‌های متعدد در تشخیص تصویر شد. از سوی دیگر، WaveNet با فراهم کردن یک مدل تولید قدرتمند برای سخن و موسیقی، حوزه سنتز صوتی را انقلابی کرد. این مدل‌ها تأثیر قابل توجهی بر حوزه‌های مربوط به خود داشته‌اند و همچنان الهام‌بخش تحقیقات و توسعه بیشتر در یادگیری عمیق هستند.

بر اساس این مقالات، به نظر می‌رسد که استفاده از طیف‌نگارها و شبکه عصبی کانولوشن روشی ارجح برای طبقه‌بندی PCG است، زیرا می‌توانند ویژگی‌های زمان-فرکانسی صداها را ضبط کرده و ویژگی‌های متمایز را به طور خودکار یاد بگیرند. با این حال، روش‌های دیگری مانند SVM ، LSTM و... نیز ممکن است اطلاعات تکمیلی را ارائه دهند و عملکرد طبقه‌بندی را بهبود بخشند.

پایگاه‌های داده

تجزیه و تحلیل صدای قلب یک تکنیک مهم برای تشخیص و نظارت بر شرایط مختلف قلبی است. با این حال، کیفیت و در دسترس بودن داده‌های صدای قلب در منابع مختلف بسیار متفاوت است. در این بخش، ما چهار مجموعه داده از ضبط صدای قلب را که برای کارهای طبقه‌بندی صدای قلب استفاده یا پیشنهاد شده‌اند، مقایسه می‌کنیم. ما مجموعه داده‌ها را بر اساس اندازه نمونه، تنوع، کیفیت، برچسب گذاری، حاشیه نویسی، توضیح و دسترسی ارزیابی می‌کنیم. ما همچنین مزایا و معایب هر مجموعه داده را برای هدف تحقیق خود مورد بحث قرار می‌دهیم.

جدول ۳-۱: پراستفاده‌ترین دیتاست‌های PCG

Database	Total recording	Normal	Abnormal	
PhysioNet/Challenge 2016	3,240	2,575	665	
PASCAL	Dataset A	124	31	93
	Dataset B	461	320	141

۱-۳ صدای قلب میشیگان (OMHSML)

Open Michigan Heart Sound & Murmur Library (OMHSML) یک منبع آنلاین است که نمونه‌های صوتی و تصویری رایگان و با کیفیتی از صداها و سوفل‌های قلبی مختلف را ارائه می‌دهد. هدف از آن کمک به دانشجویان و پزشکان در تقویت مهارت‌های سمع‌شناختی با پوشش چهار ناحیه قلب است: راس، آئورت، ریوی و تریکوسپید. OMHSML توسط مربیان متخصص از دانشکده پزشکی دانشگاه میشیگان توسعه و نگهداری می‌شود. با این حال، OMHSML دارای محدودیت‌هایی است، مانند محدوده محدود، عدم تعامل، وابستگی به دستگاه و کیفیت اینترنت و قدیمی بودن احتمالی. بنابراین، کاربران باید یادگیری خود را با منابع و روش‌های دیگر تکمیل کنند. [۴۲]

۲-۳ چالش پاسکال ۲۰۱۱ (CHSC2011)

PASCAL Classifying Heart Sounds Challenge 2011 (CHSC2011) یک مسابقه یادگیری ماشینی بود که هدف آن توسعه روش‌هایی برای تجزیه و تحلیل صداها و سوفل‌های قلب بود. توسط P. a. N. Bentley, M. Coimbra, G. و S. Mannor. در این مسابقه از دو مجموعه داده صدای قلب استفاده شد: یکی از یک برنامه آیفون مورد استفاده عموم، و دیگری از یک آزمایش بیمارستانی با استفاده از گوشی پزشکی دیجیتال. این مسابقه دو وظیفه داشت: پیدا کردن صدای قلب اول و دوم در داده‌ها و برچسب‌گذاری داده‌ها در دسته‌های مختلف بر اساس نوع صدا یا سوفل. داده‌های CHSC2011 دارای مزایا و معایبی بودند. مزایای آن این بود که بزرگ، متنوع، واقع‌گرایانه، پر از نویز و در دسترس بود. اشکالات این بود که نامتعادل، نامشخص (Unclear) و قدیمی بود. [۴۱]

۳-۳ مجموعه پادکست صدای‌های قلب تگزاس (THI)

موسسه قلب تگزاس (THI) دارای یک آزمایشگاه صداها و سوفل‌های قلب است که در سال ۱۹۷۳ توسط متخصصان قلب جیمز ام ویلسون و رابرت جی هال MD ساخته شده است. این مجموعه‌ای از نمونه‌های صوتی و تصویری از صداها و سوفل‌های مختلف قلب است که مفید است. برای آموزش و یادگیری نحوه گوش دادن به قلب این آزمایشگاه بیش از ۱۴۰۰ نمونه از بیماران در سنین، جنسیت و شرایط مختلف سلامت دارد. همچنین دارای یک سری پادکست است که نحوه ارتباط صداها و سوفل‌های مختلف قلب با ساختار، عملکرد و تشخیص قلب را توضیح می‌دهد. آزمایشگاه و پادکست برای هر کسی که می‌خواهد در مورد سمع و سمع بیشتر بیاموزد رایگان و در دسترس است. آنها نمونه‌هایی با کیفیت بالا و واقعی از شرایط مختلف قلبی ارائه می‌دهند. با این حال، آنها محدودیت‌هایی نیز دارند. آنها تعاملی یا سازگار با نیازهای کاربران نیستند. آنها برای پخش فایل‌های صوتی به دستگاه و کیفیت اینترنت بستگی دارند. آنها ممکن است با آخرین تحقیقات و عملکرد در قلب و عروق به روز نباشند. [۴۰]

۴-۳ چالش فیزیوننت ۲۰۱۶

مجموعه داده PhysioNet/CinC Challenge 2016 مجموعه داده ای از ۳۱۲۵ ضبط صدای قلب از منابع مختلف بالینی و غیر بالینی است. همچنین برچسب هایی برای صداهای طبیعی و غیر طبیعی قلب و همچنین محل صدای قلب اول و دوم ارائه می دهد. مزایای این مجموعه داده این است که بزرگترین و جامع ترین مجموعه داده از صداهای قلب موجود است، سناریویی چالش برانگیز و واقع بینانه برای آزمایش الگوریتم های طبقه بندی صدای قلب ارائه می دهد و دارای ضبط با کیفیت بالا و حداقل نویز است. معایب این مجموعه داده این است که هیچ اطلاعاتی در مورد انواع خاص بیماری های قلبی یا شدت شرایط ارائه نمی دهد، هیچ حاشیه نویسی یا توضیحی برای صداهای قلب یا برچسب ها ارائه نمی دهد، و به طور عمومی ارائه نمی شود. موجود است و برای دسترسی نیاز به ثبت و تایید دارد. [۳۸]

بر اساس مقایسه ما، ما پیشنهاد می کنیم که مجموعه داده PhysioNet/CinC Challenge 2016 ارجح ترین و کاربردی ترین مجموعه داده برای تحقیق ما می باشد. زیرا دارای مزایای زیر است:

- دارای بزرگترین و متنوع ترین حجم نمونه است که می تواند تعمیم پذیری و اعتبار نتایج ما را افزایش دهد.
- دارای بالاترین کیفیت و ثبات ضبط است که می تواند خطاها و سوگیری های ناشی از نویز یا مصنوعات را کاهش دهد.
- دارای استانداردترین و عینی ترین برچسب ها است که می تواند ارزیابی و مقایسه الگوریتم های ما را تسهیل کند.
- جدیدترین و مرتبط ترین داده ها را دارد که می تواند وضعیت فعلی و روند تجزیه و تحلیل صدای قلب را منعکس کند.

این پایگاه داده حاوی حدود ۳۰ ساعت صدای قلب است که شامل ۲۳۳۵۱۲ صدای قلب از ۱۱۶۸۶۵ ضربان قلب، در ۴۴۳۰ ضبط از ۱۰۷۲ نفر سالم و بیمار با وضعیت های مختلف (مثل بیماری های دریچه قلب و عروق قلب) در

رده‌های سنی مختلف، از نقاط مختلف قلب گرفته شده است. زمان صداهای ضبط شده از ۵ ثانیه تا ۱۲۰ ثانیه متغیر است. داده‌های دیگری که در اختیار قرار داده شده‌اند عبارت‌اند از اطلاعات جمعیت‌شناسی (سن و جنس)، اطلاعات ضبط (مکان ضبط و زمان صدای ضبط شده) سیگنال‌های همزمان مثل (ECG)، نرخ نمونه‌برداری و نوع سنسور استفاده شده است. [۳۴]

به طور کلی، صداهای قلبی که ضبط شده‌اند را می‌توان به دو دسته صداهای سالم و بیمار تقسیم کرد. صداهای سالم مربوط به افرادی هستند که هیچ مشکلی در دریچه‌های قلبی ندارند. اما صداهای بیمار مربوط به افرادی هستند که با اختلالات مختلف در دریچه‌های قلبی مانند نقص، پرولاپس، انقباض یا تنگی آئورت یا عمل جراحی درگیر هستند. تمام صداهای ضبط شده با فرکانس نمونه‌برداری ۲۰۰۰ هرتز دارند. این پایگاه داده در [۳۲، ۳۹] بیشتر توضیح داده شده است. جدول زیر نشان می‌دهد که چگونه این پایگاه داده برای آموزش و آزمون در این مطالعه استفاده شده است.

جدول ۳-۲: جزئیات مجموعه‌های آزمون و آموزش پایگاه داده [۳۲، ۳۹]

Database	patients	recordings	Proportion of recordings(%) Abnormal	beats
Training-a	121	409	67.5	14559
Training-b	106	490	14.9	3353
Training-c	31	31	64.5	1808
Training-d	38	55	47.3	853
Training-e	356	2141	7.1	59593
Training-f	112	114	27.2	4259
Total	764	3153	18.1	84425
Test-b	45	205	15.6	1269
Test-c	14	14	64.3	853
Test-d	17	24	45.8	260
Test-e	153	883	6.7	26724
Test-g	44	116	18.1	2048
Test-i	35	35	60.0	1286
Total	308	1277	12.0	32440

فصل چهارم

الگوریتم پیشنهادی جهت دسته‌بندی سیگنال PCG

در این فصل ابتدا به بررسی تحلیل زمان-فرکانس سیگنال‌های غیرایستادن و ویژگی‌های زمان-فرکانسی مپیردازیم و سپس به تفصیل به بررسی الگوریتم مورد استفاده در این پژوهش برای دسته‌بندی صداهای قلب خواهیم پرداخت. هدف این الگوریتم تشخیص بیماری‌های قلبی از طریق تحلیل فایل‌های صوتی است. این الگوریتم از چندین مرحله تشکیل شده است که عبارتند از: پیش پردازش داده‌ها، ساختن و آموزش یک شبکه عصبی کانولوشن (CNN) و ارزیابی عملکرد مدل.

۱-۴ تحلیل زمان - فرکانس سیگنال‌های غیرایستادن

تحلیل سیگنال‌های غیرایستادن (که محتوای فرکانسی آنها با زمان تغییر میکند) در حوزه زمان - فرکانس صورت می‌گیرد که در آن اطلاعات زمانی و فرکانسی سیگنال توأمأ در دسترس می‌باشند. [۳۳] برای انتقال سیگنال زمان گسسته N نقطه‌ای $x[n]$ به حوزه زمان - فرکانس میتوان از تبدیل زمان - فرکانس درجه دوم ($QTFD^{13}$) استفاده کرد که در رابطه (۱) نشان داده شده است. [۳۳]

$$\rho_x[n, k] = 2 DFT_{n \rightarrow k} \left\{ G[n, m]_n^* (z_x[n+m] z_x^*[n-m]) \right\} \quad (1)$$

در رابطه بالا $z_x[n] = x[n] + jH\{x[n]\}$ سیگنال تحلیلی متناظر با $x[n]$ و $H\{\}$ عملگر تبدیل هیلبرت است. همچنین $G[n, m]$ کرنل زمان-تأخیر $QTFD$ و $*$ ، کانولوشن گسسته در حوزه زمان می‌باشند. تبدیل زمان - فرکانس $x[n]$ را با $\rho_x[n, k]$ نمایش می‌دهیم که یک ماتریس $M \times N$ که M تعداد نقاط FFT^{14} مورد استفاده برای محاسبه TFD^{15} است [۳۳]. کرنل‌های مختلف امکان تعریف TFD ‌های مختلف را به ما می‌دهند. برای تحلیل سیگنال‌های غیرایستادن چند مؤلفه‌ای، به $QTFD$ ‌هایی نیاز است که ضمن حفظ رزولوشن مناسب، اثر مؤلفه‌های مختلف روی یکدیگر را در حوزه زمان - فرکانس کم کنند. این $QTFD$ ‌ها را توزیع‌های زمان - فرکانس با تداخل کاسته شده مینامند. جدول ۱ برخی از $RI-TFDs^{16}$ را در حوزه زمان-تأخیر نشان می‌دهد. جزییات بیشتر در مورد آنها را میتوان در [۳۳] یافت.

جدول ۴-۱: برخی از RI-TFDs و کرنل آنها در حوزه زمان-تأخیر [۳۳]

Distribution	$G[n,m]$	Parameters
WVD ¹⁷	$\delta[n]$	N / A
SWVD ¹⁸	$\delta[n]w[m]$	$w[n]$: <i>Hamming window</i> N / 4 : Window length
CWD ¹⁹	$\frac{\sqrt{\pi\sigma}}{2 m } \exp\left(\frac{-\pi^2\sigma n^2}{4m^2}\right)$	$\sigma = 5$
SPEC ²⁰	$w[n+m]w[n-m]$	$w[n]$: <i>Hamming window</i> N / 4 : Window length
MBD ²¹	$\frac{\cosh^{-2\beta}(n)}{\sum_n \cosh^{-2\beta}(n)}$	$\beta = 0.01$
EMBD ²²	$\frac{\cosh^{-2\beta}(n)}{\sum_n \cosh^{-2\beta}(n)} \frac{\cosh^{-2\alpha}(n)}{\sum_n \cosh^{-2\alpha}(n)}$	$\beta = 0.01, \alpha = 0.9$

۲-۴ ویژگی‌های زمان - فرکانس

ویژگی‌های زمان - فرکانس سیگنال $x[n]$ از QTDF آن که در رابطه (۱) ارائه شده استخراج میگردند. مهم‌ترین این ویژگی‌ها در این بخش ارائه میشوند. جزئیات بیشتر در مورد این ویژگی‌ها در [۳۴, ۴۴] آمده است.

۱. انرژی سیگنال:

انرژی سیگنال در حوزه زمان - فرکانس در فرمول (۲) داده شده است و میتواند به‌عنوان یک ویژگی استخراج شود.

$$E_x = \sum_{n=1}^N \sum_{k=1}^M \rho_x[n, k] \quad (۲)$$

۲. ویژگی‌های زمان - فرکانس بر اساس فرکانس لحظه‌ای:

فرکانس لحظه‌ای سیگنال $x[n]$ به صورت رابطه (۳) تخمین زده میشود.

$$f_{i,x}[n] = \frac{f_s}{2M} \frac{\sum_{k=1}^M k \rho_x[n, k]}{\sum_{k=1}^M \rho_x[n, k]} \quad (۳)$$

آمارگان‌های فرکانس لحظه‌ای (مثلاً بیشینه، کمینه و انحراف معیار آن) را میتوان به‌عنوان ویژگی در نظر گرفت.

۳. معیار تمرکز انرژی:

این معیار، تمرکز انرژی سیگنال $x[n]$ را در حوزه زمان - فرکانس به‌صورت کمی اندازه‌گیری میکند. این معیار را میتوان با استفاده از رابطه (۴) یافت.

$$EC_x = \left(\sum_{n=1}^N \sum_{k=1}^M |\rho_x[n, k]|^2 \right)^{\frac{1}{2}} \quad (۴)$$

۴. آنتروپی شانون:

تمرکز انرژی و تفکیک‌پذیری توزیع زمان - فرکانس سیگنال $x[n]$ را ارزیابی می‌کند (به‌نحوی که هر چه مقدار آنتروپی شانون بیشتر باشد، تفکیک‌پذیری و تمرکز انرژی توزیع کمتر است و هر چه مقدار آنتروپی کمتر باشد،

تفکیک پذیری و تمرکز انرژی توزیع زمان - فرکانس بیشتر است) آنتروپی شانون $\rho_x[n, k]$ از رابطه (۵) قابل محاسبه است:

$$SE_x = - \sum_{n=1}^N \sum_{k=1}^M \rho_x[n, k] \log_2(\rho_x[n, k]) \quad (۵)$$

۵. آنتروپی Renyi :

میزان پیچیدگی توزیع زمان - فرکانس را مشخص می کند به نحوی که هر چه مقدار آنتروپی Renyi کمتر باشد، نشانگر پیچیدگی کمتر توزیع زمان - فرکانس است. کمتر بودن پیچیدگی یک توزیع زمان - فرکانس را میتوان معادل تفکیک پذیری بالاتر و تمرکز انرژی بیشتر دانست. این آنتروپی در رابطه (۶) داده شده است که در آن عدد صحیح α معمولاً بزرگتر از یک) مرتبه آنتروپی را مشخص میکند.

$$RE_x(\alpha) = \frac{1}{1-\alpha} \log_2 \sum_{n=1}^N \sum_{k=1}^M \rho_x^\alpha[n, k] \quad (۶)$$

دقت کنیم که این آنتروپی محدودیت آنتروپی شانون را ندارد.

۶. همواری TFD سیگنال:

این معیار که نشان می دهد توان سیگنال در حوزه زمان - فرکانس چگونه توزیع شده است در رابطه (۷) آمده است.

$$TFF_x = \frac{\left(\prod_{n=1}^N \prod_{k=1}^M \rho_x[n, k] \right)^{\frac{1}{NM}}}{\sum_{n=1}^N \sum_{k=1}^M \rho_x[n, k]} \quad (۷)$$

۷. ویژگی های مبتنی بر تجزیه مقدار تکین (SVD^{23}):

در تجزیه مقدار تکین، ماتریس توزیع زمان - فرکانس $M \times N$ ، ρ_x به حاصل ضرب سه ماتریس S ، U و V تبدیل می شود به طوری که :

$$\rho_x = USV^H \quad (۸)$$

که در U و V ماتریس های یک متعامد و به ترتیب با ابعاد $N \times N$ و $M \times M$ و S یک ماتریس شبه قطری متعامد است. عناصر روی قطر ماتریس S مقادیر ویژه ماتریس ρ_x هستند. آمارگان این مقادیر (مانند بیشینه و یا کمینه مقادیر ویژه) را میتوان به عنوان ویژگی های سیگنال در حوزه زمان - فرکانس در نظر گرفت.

۸. ویژگی‌های مبتنی بر پردازش تصاویر توزیع‌های زمان-فرکانس:

علاوه بر ویژگی‌های ارائه شده در قسمت‌های قبل، با توجه به اینکه یک توزیع زمان - فرکانس را میتوان یک تصویر در نظر گرفت، امکان استفاده از تکنیک‌های پردازش تصاویر برای استخراج ویژگی از یک توزیع زمان - فرکانس وجود دارد. ابتدا قطعه‌هایی از تصویر توزیع زمان - فرکانس که شامل اطلاعات مهمتری هستند شناسایی شده و به یک تصویر دودویی تبدیل می‌شود و نتیجه یک ماتریس دودویی $\rho'_x[n, k]$ خواهد بود. ویژگی‌های زمان - فرکانس می‌توانند برحسب گشتاور مرتبه p, q ام، ماتریس $\rho'_x[n, k]$ محاسبه گردند که در رابطه (۹) آماده است.

$$m_{pq} = \sum_n \sum_k n^p k^q \rho'_x[n, k] \quad (9)$$

$$\bar{n} = m_{10}/m_{00}, \bar{k} = m_{01}/m_{00}$$

این تحقیق از ویژگی‌های زمان - فرکانس ارائه شده در این بخش برای دسته‌بندی صدای قلب استفاده کرده است.

۳-۴ پیش‌پردازش

در مرحله پیش‌پردازش داده‌ها، روش‌های گوناگونی به جهت یکسان‌سازی، متعادل‌سازی و بهینه‌سازی داده‌ها به منظور آموزش بهتر مدل استفاده شده است. در ابتدا به معرفی مهم‌ترین این روش‌ها پرداخته می‌شود و در ادامه، مراحل پیش‌پردازش به تفصیل توضیح داده می‌شود.

• نرمال‌سازی داده‌ها (Dataset Normalization)

یک مفهوم از نرمال کردن، که به استاندارد کردن نیز موسوم است و در تحلیل شبکه‌های عصبی مصنوعی و تحلیل پوششی داده‌ها کاربرد دارد. برای استاندارد کردن یک عنصر باید آن عنصر را منهای میانگین کرده و بر انحراف معیار تقسیم نماییم. در اینجا برای نرمال کردن یک عنصر باید آن عنصر را منهای مینیمم کرده و بر دامنه تغییرات تقسیم نماییم. [۴۳]

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (10)$$

• اسپکتروگرام: پردازش صوت با استفاده از روش های پردازش تصویر

اسپکتروگرام نمایشی از طیف فرکانسی صوت یا دیگر سیگنال هایی است که نسبت به زمان تغییرات زیادی دارند. اسپکتروگرام معمولا با نام های دیگری مثل *Voiceprints* یا *voicegrams* نیز مورد استفاده قرار می گیرد. از اسپکتروگرام می توان برای شناسایی کلمات گفته شده به صورت آوایی و تحلیل آواهای مختلف حیوانات استفاده کرد. یکی از کاربردهای بسیار مهم اسپکتروگرام، تحلیل صوت با استفاده از روشهای پردازش تصویر می باشد. چون در این روش، صوت به صورت تصویر مدل سازی می شود.

اسپکتروگرام معمولا با یکی از دو روش زیر ساخته می شود:

۱. تقریب زدن به صورت یک بانک فیلتری (مجموعه ای از فیلتر های میان گذر)

۲. استفاده از تبدیل فوریه در حوزه ی زمان

روش اول معمولا در پردازش های آنالوگ مورد استفاده قرار می گیرد و سیگنال ورودی را به باندهای فرکانسی مختلف تبدیل می کند. اندازه ی دامنه ی خروجی هر کدام از فیلترها، یک ترنسدمپوسر که اسپکتروگرام را به صورت یک تصویر بر روی کاغذ ذخیره میکند، را کنترل می نماید. عموما دستگاههای طیفسنج آزمایشگاهها از این روش برای به دست آوردن اسپکتروگرام استفاده می کنند.

روش دوم در پردازش های دیجیتال مورد بهره برداری قرار می گیرد. و از تبدیل فوریه در حوزه ی زمان بهره می برد. نرم افزارهایی مثل متلب یا پایتون برای به دست آوردن اسپکتروگرام از این روش استفاده می کنند. [۳۵،۳۳]

• روش کدبندی وان هات (*One Hot Encoding*)

متغیر «طبقه ای» (*Categorical*)، نوع داده ای است که تنها می تواند تعداد محدودی مقدار را بگیرد. برای مثال، اگر یک نظرسنجی وجود داشته باشد که از افراد برند خودرو آن ها را پرسیده باشند، نتیجه یک متغیر طبقه ای خواهد بود؛ به این دلیل که، برند خودرویی که افراد می توانند داشته باشند به چند شرکت ساخت خودرو سازی خاص (در همان کشور، در همان کشور و چند کشور دیگر یا در کلی ترین حالت به همه برندهای خودروی موجود در جهان) محدود می شود. بنابراین، پاسخها محدود به یک سری گزینه خاص خواهد بود. یا اگر از افراد بپرسند که رنگ مورد علاقه آن ها چیست، پاسخهای افراد محدود به یک سری گزینه خاص (اسامی رنگها یعنی مثلا: سفید، آبی، قرمز، مشکی، قهوه ای و دیگر موارد) خواهد بود. در صورت استفاده از این نوع متغیرها در اغلب مدل های یادگیری ماشین (*Machine Learning*)، پیغام خطا صادر خواهد شد. دلیل این امر آن است که بسیاری از مدل ها، امکان انجام پردازش مستقیم و بدون انجام کدبندی (*Encoding*) را روی داده های طبقه ای ندارند. یکی از روش های محبوب کدبندی داده های طبقه ای با عنوان کدبندی وان هات (*One Hot Encoding*) شناخته می شود.

روش کدبندی *One-Hot*، یکی از پرکاربردترین رویکردها است و عملکرد آن به جز در مواردی که متغیر دسته‌ای مقادیر خیلی زیادی بگیرد، بسیار خوب است (معمولاً از این روش برای متغیرهایی که بیش‌تر از ۱۵ مقدار متفاوت بگیرند، مناسب نیست). کدبندی *One-Hot* ستون‌های دودویی (*binary*) جدیدی می‌سازد که هر یک مربوط به یکی از مقادیری هستند که متغیر به خود می‌گیرد.


این نوع کدگذاری به مدل این امکان را می‌دهد تا کلاس‌ها را به‌عنوان موجودیت‌های مجزا و مستقل، به جای مقادیر ترتیبی در مقیاس پیوسته، در نظر بگیرد. این می‌تواند به بهبود عملکرد مدل با اجازه دادن به آن برای یادگیری مرزهای تصمیم‌گیری دقیق‌تر بین کلاس‌ها کمک کند. [۳۷]

مراحل پیش پردازش به تفصیل عبارت‌اند از :

(۱) وارد کردن کتابخانه‌های مورد نیاز و انتقال فایل‌های صوتی از پوشه‌های مختلف به یک پوشه مشترک. در این بخش، کد از کتابخانه‌های *numpy, pandas, tensorflow, matplotlib, os, wave, pylab, sklearn, pathlib, scipy* استفاده می‌کند. همچنین، کد با استفاده از تابع *shutil.copy* تمام فایل‌های صوتی را از پوشه‌های *training-a* تا *training-f* به پوشه *all_files* منتقل می‌کند.


(۲) باز کردن فایل‌های صوتی و خواندن اطلاعات آنها. در این بخش، کد با استفاده از تابع *os.listdir* لیستی از نام‌های فایل‌های صوتی را می‌سازد. سپس، با استفاده از تابع *wave.open* یک فایل صوتی خاص را باز می‌کند و با استفاده از تابع *np.frombuffer* سیگنال آن را به صورت آرایه نامپای تبدیل می‌کند. سپس، سیگنال را با استفاده از حداکثر و حداقل مقادیر آن نرمال‌سازی می‌کند. در نهایت، با استفاده از تابع *plt.plot* و *plt.specgram* سیگنال و اسپکتروگرام آن را نمایش می‌دهد.

شکل ۴-۱: نمایش انرژی و اسپکتروگرام یک فایل صوتی (a0007)



۳) خولدن تمام تصاویر و تبدیل آنها به آرایه های نامپای و همچنین برچسب های کلاس. در ابتدای این مرحله توسط یک تابع، تمامی فایل های صوتی به جهت یکسان سازی داده ها به صوت های ۵ ثانیه ای تبدیل می شود. سپس، کد با استفاده از تابع `cv2.imread` تمام تصاویر استخراج شده از فایل های صوتی را خوانده و با استفاده از تابع `transform.resize` آنها را به اندازه $128 \times 128 \times 3$ تغییر می دهد. سپس، با استفاده از تابع `np.asarray` آرایه های نامپای مربوط به تصاویر را می سازد. همچنین، کد با استفاده از تابع `open` فایل های `header` مربوط به فایل های صوتی را باز کرده و برچسب کلاس آنها را به صورت ۰ یا ۱ مشخص می کند. در صورت نیاز، کد با استفاده از لایه های `data_augmentation` تصاویر را به صورت تصادفی چرخانده و نمونه های جدید را به داده ها اضافه می کند.


شکل ۴-۲: نمایش ۹ نمونه از اسپکتروگرام ها به صورت تصادفی (پس از انجام *data_augmentation*)



۴-۴ ساختن و آموزش مدل CNN

در مرحله ساختن و آموزش *CNN*، با استفاده از کلاس *Sequential* یک معماری *CNN* با چندین لایه از کانولوشن، مکس پولینگ، دراپ آوت و دنس می‌سازیم. سپس، با استفاده از تابع *model.compile* مدل را با تابع هزینه *categorical_crossentropy*، بهینه ساز *adamax* و معیار *binary_accuracy* کامپایل می‌کنیم. سپس، با استفاده از تابع *model.fit* مدل را با داده های آموزش و داده های اعتبارسنجی برای ۳۰ دوره (*epoch*) آموزش می‌دهیم.

شکل ۴-۳: شمای کلی از مدل استفاده شده به جهت دسته‌بندی




۵-۴ ارزیابی عملکرد مدل

در مرحله ارزیابی عملکرد مدل، با استفاده از تابع `model.evaluate` مدل را روی داده‌های تست قبل و بعد از آموزش ارزیابی می‌کنیم. سپس، با استفاده از تابع `model.predict` برچسب‌ها را از داده‌های تست پیش‌بینی می‌کنیم و چند نمونه صحیح را نمایش می‌دهیم. در نهایت، با استفاده از تابع `confusion_matrix` یک ماتریس درهم‌ریختگی از برچسب‌های واقعی و پیش‌بینی شده می‌سازیم و با استفاده از تابع `classification_report` گزارشی از معیارهای دقت، بازخوانی، امتیاز $F1$ و پشتیبانی برای هر کلاس چاپ می‌کنیم.

با استفاده از این الگوریتم بنده توانستم به $binary_accuracy$ میانگین ۹۲٪ دست پیدا کنم. به صورت میانگین برای سایر دقت‌های ذکر شده نظیر $F1$ نیز، همین عدد بدست آمده است.

شکل ۴-۴: ماتریس درهم ریختگی داده‌های تست



فصل پنجم

جمع‌بندی و نتیجه‌گیری

بیماری‌های قلبی و عروقی از مهم‌ترین عوامل مرگ و میر در جهان هستند و بر اساس پیش‌بینی‌ها تعداد فوت‌شدگان به خاطر آن‌ها تا سال ۲۰۳۰ تقریباً دو برابر خواهد شد. گوش کردن به صداهای قلب یک روش سنتی و موثر برای تشخیص و درمان این بیماری‌ها است که نیاز به مهارت و تجربه پزشک دارد. با پیشرفت تکنولوژی، روش‌های خودکار برای دسته‌بندی و تحلیل صدای قلب با استفاده از سامانه‌های کامپیوتری و هوش مصنوعی ارائه شده‌اند که می‌توانند دقت و سرعت تشخیص را افزایش دهند و هزینه و زمان مراجعه بیمار را کاهش دهند.

در فصل دوم پژوهش، ما به مروری بر مطالعات و روش‌های مهم تحلیل سیگنال‌های PCG که نمایش گرافیکی صداهای قلب هستند، پرداختیم. این روش‌ها را می‌توان به سه رویکرد اصلی پردازش سیگنال، یادگیری ماشین و یادگیری عمیق تقسیم کرد. یادگیری عمیق به عنوان یک روش جدید و موثر در این زمینه مورد توجه قرار گرفته و نتایج خوبی را ارائه داده است. ما همچنین پایگاه داده‌های مختلفی که در این روش‌ها استفاده شده‌اند را معرفی کردیم. این پایگاه داده‌ها شامل داده‌های عمومی مانند PASCAL-11، MHSML-2014، PhysioNet-2016 و Yaseen-2018 و داده‌های خصوصی هستند. سیگنال‌های PCG را می‌توان به دو دسته نرمال و غیرنرمال دسته‌بندی کرد و همچنین بر اساس انواع بیماری‌ها و عوامل دیگر تفکیک کرد. ما همچنین مراحل پیش‌پردازش، استخراج ویژگی و طبقه‌بندی را برای این سیگنال‌ها مورد بررسی قرار دادیم. در مرحله پیش‌پردازش، در روش‌های مبتنی بر پردازش سیگنال، فیلترینگ، کاهش نمونه برداری و... انجام می‌شود. اما روش‌های مبتنی بر یادگیری ماشین، تبدیل‌های پیچیده‌تری مانند CWT اعمال می‌شوند. در مرحله طبقه‌بندی، از روش‌های هیورستیکی مبتنی بر مکان‌های S1 و S2 یا روش‌های نظارت شده ای همانند SVM یا DNN استفاده می‌شود. طبقه‌بندی می‌تواند در سطح سیگنال یا چرخه و به صورت دودویی یا چندکلاسه باشد.

در فصل سوم، برای انجام تجزیه و تحلیل صدای قلب به عنوان یک روش تشخیصی و نظارتی برای بیماری‌های قلبی، چهار مجموعه داده مختلف را مورد بررسی قرار دادیم. معیارهایی مانند حجم نمونه، تنوع، کیفیت، برچسب‌گذاری، حاشیه‌نویسی، توضیح و دسترسی را برای ارزیابی مجموعه داده‌ها به کار بردیم. همچنین نقاط قوت و ضعف هر مجموعه داده را بر اساس هدف تحقیق ما مطرح کردیم. نتیجه مقایسه ما نشان داد که مجموعه داده PhysioNet/CinC Challenge 2016 دارای بیشترین مزایا و کمترین معایب است و می‌تواند نتایج ما را با اعتبار

و قابلیت تعمیم بالاتری ارائه دهد. بنابراین، این مجموعه داده را به عنوان پایگاه داده مناسب برای این تحقیق انتخاب کردیم.

در فصل چهارم روش پیشنهادی این تحقیق از ویژگی‌های زمان-فرکانس استخراج شده از سیگنال‌های PCG جهت دسته‌بندی آن‌ها استفاده می‌کند. نتایج پیاده‌سازی این روش بر روی پایگاه داده چالش ۲۰۱۶ فیزیونت نشان‌دهنده عملکرد بهتر راهکار پیشنهادی در مقایسه با بسیاری از روش موجود در چند دهه اخیر و دستیابی به دقت میانگین ۹۲٪ در دسته‌بندی صداهای قلبی است. نتایج بدست آمده از اعمال روش پیشنهاد داده شده به سیگنال‌های واقعی ثبت شده نشان داد که ویژگی‌های زمان-فرکانس عملکرد بسیار خوبی در دسته‌بندی صداهای ضبط شده قلب نشان می‌دهند و عملکرد بهتری نسبت به متداول‌ترین ویژگی حوزه زمان و فرکانس استفاده شده برای تشخیص این الگوها در کارهای انجام شده پیشین دارد. این پیشرفت با بررسی امکان استخراج دیگر ویژگی‌های زمان-فرکانس، پیش‌پردازش مناسب روی داده‌ها و همچنین با استفاده از معماری شبکه عصبی کانولوشن حاصل شده است.

دسته‌بندی PCG وظیفه شناسایی صداهای قلبی نرمال و غیرنرمال بر اساس سیگنال‌های فونوکاردیوگرام (PCG) است. یک روش نوآورانه ممکن برای مقالات آینده در دسته‌بندی PCG، استفاده از روش‌های یادگیری عمیق چندمنظر (Multi-View Deep Learning) است که می‌توانند از اطلاعات مکمل از نمایش‌های مختلف سیگنال‌های PCG، مانند حوزه زمان، حوزه فرکانس و حوزه زمان-فرکانس استفاده کنند. روش‌های یادگیری عمیق چندمنظر می‌توانند ویژگی‌های سطح بالا (High-Level) را از هر نمایاد بگیرند و آن‌ها را ادغام کنند تا نمایشی مستحکم و جامع از سیگنال‌های PCG به دست آورند. این می‌تواند دقت و تعمیم دسته‌بندی مدل‌های PCG را بهبود بخشد، به خصوص برای داده‌های نویزی و ناهمگن. مقاله اخیر توسط Zhang و همکارانش [۲۹] یک شبکه عمیق چندمنظر بر اساس شبکه‌های عصبی پیچشی (CNNs) و شبکه‌های عصبی پیچشی گرافی (GCNs) برای دسته‌بندی PCG پیشنهاد داد و نتایج برتر را در دو مجموعه داده مرجع کسب کرد.

مراجع

- [1] K. Rezaee and J. Haddadnia, "Design and performance evaluation of intelligent system to segregate and classify the phonocardiograph abnormalities using matched filter and multilayer perceptron-back propagation neural networks, " *Pajoohandeh Journal*, vol. 18, no. 5, pp. 277-286, 2013.
- [2] F. Javed, P. Venkatachalam, and A. F. MH, "A signal processing module for the analysis of heart sounds and heart murmurs, " in *Journal of Physics: Conference Series*, 2006, vol. 34, no. 1, p. 1098: IOP Publishing.
- [3] A.D. Ricke, R.J. Povinelli, M.T. Johnson, Automatic segmentation of heart sound signals using hidden Markov models, in: *Computers in Cardiology*, 2005, IEEE, 2005, pp. 953–956.
- [4] J. Oliveira, A. Castro, M. Coimbra, Exploring embedding matrices and the entropy gradient for the segmentation of heart sounds in real noisy environments, in: *2014 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, IEEE, 2014, pp. 3244–3247.
- [5] R. Prasad, G. Yilmaz, O. Chetelat, M.M. Doss, Detection of S1 and S2 locations in phonocardiogram signals using zero frequency filter, in: *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing*, ICASSP, IEEE, 2020, pp. 1254–1258.
- [6] R. Touahria, A. Hacine-Gharbi, P. Ravier, Discrete wavelet based features for PCG signal classification using hidden Markov models, in: *ICPRAM*, 2021, pp. 334–340.
- [7] A.K. Abbas, R. Bassam, R. Kasim, Mitral regurgitation PCG-signal classification based on adaptive db-wavelet, in: *4th Kuala Lumpur International Conference on Biomedical Engineering 2008*, Springer, 2008, pp. 212–216.
- [8] S. Ari, G. Saha, In search of an optimization technique for artificial neural network to classify abnormal heart sounds, *Appl. Soft Comput.* 9 (1) (2009) 330–340.
- [9] I. Grzegorzcyk, M. Soliński, M. Łepek, A. Perka, J. Rosiński, J. Rymko, K. Stępień, J. Gierałtowski, PCG classification using a neural network approach, in: *2016 Computing in Cardiology Conference, CinC*, IEEE, 2016, pp. 1129–1132.
- [10] F. Safara, S. Doraisamy, A. Azman, A. Jantan, A.R.A. Ramaiah, Multi-level basis selection of wavelet packet decomposition tree for heart sound classification, *Comput. Biol. Med.* 43 (10) (2013) 1407–1414.
- [11] M. Singh, A. Cheema, Heart sounds classification using feature extraction of phonocardiography signal, *Int. J. Comput. Appl.* 77 (4) (2013).
- [12] H. Tang, Z. Dai, Y. Jiang, T. Li, C. Liu, PCG classification using multidomain features and SVM classifier, *BioMed Res. Int.* 2018 (2018).

- [13] S. Ajitkumar Singh, S. Ashinikumar Singh, N. Dinita Devi, S. Majumder, Heart abnormality classification using PCG and ECG recordings, *Computación Y Sistemas* 25 (2) (2021) 381–391.
- [14] A. Bourouhou, A. Jilbab, C. Nacir, A. Hammouch, Heart Sound Signals Segmentation and Multiclass Classification, *International Association of Online Engineering*, 2020.
- [15] A. Baccouche, B. Garcia-Zapirain, C. Castillo Olea, A. Elmaghraby, Ensemble deep learning models for heart disease classification: a case study from Mexico, *Information* 11 (4) (2020) 207.
- [16] Y. He, W. Li, W. Zhang, S. Zhang, X. Pi, H. Liu, Research on segmentation and classification of heart sound signals based on deep learning, *Appl. Sci.* 11 (2) (2021) 651.
- [17] T.H. Chowdhury, K.N. Poudel, Y. Hu, Time-frequency analysis, denoising, compression, segmentation, and classification of PCG signals, *IEEE Access* 8 (2020) 160882–160890.
- [18] S.L. Oh, V. Jahmunah, C.P. Ooi, R.-S. Tan, E.J. Ciaccio, T. Yamakawa, M. Tanabe, M. Kobayashi, U.R. Acharya, Classification of heart sound signals using a novel deep WaveNet model, *Comput. Methods Programs Biomed.* 196 (2020) 105604.
- [19] P. Dhar, S. Dutta, V. Mukherjee, Cross-wavelet assisted convolution neural network (AlexNet) approach for phonocardiogram signals classification, *Biomed. Signal Process. Control* 63 (2021) 102142.
- [20] A. Krizhevsky, I. Sutskever, G.E. Hinton, Imagenet classification with deep convolutional neural networks, *Adv. Neural Inf. Process. Syst.* 25 (2012).
- [21] A.v.d. Oord, S. Dieleman, H. Zen, K. Simonyan, O. Vinyals, A. Graves, N. Kalchbrenner, A. Senior, K. Kavukcuoglu, Wavenet: A generative model for raw audio, 2016, arXiv preprint arXiv:1609.03499.
- [22] T. Li, Y. Yin, K. Ma, S. Zhang, M. Liu, Lightweight end-to-end neural network model for automatic heart sound classification, *Information* 12 (2) (2021) 54.
- [23] M. Gjoreski, A. Gradišek, B. Budna, M. Gams, G. Poglajen, Machine learning and end-to-end deep learning for the detection of chronic heart failure from heart sounds, *IEEE Access* 8 (2020) 20313–20324.
- [24] F. Noman, S.-H. Salleh, C.-M. Ting, S.B. Samdin, H. Ombao, H. Hussain, A Markov-switching model approach to heart sound segmentation and classification, *IEEE J. Biomed. Health Inf.* 24 (3) (2019) 705–716.
- [25] F. Safara, S. Doraisamy, A. Azman, A. Jantan, S. Ranga, Wavelet packet entropy for heart murmurs classification, *Adv. Bioinform.* 2012 (2012).
- [26] G .D. Clifford et al., “Classification of normal/abnormal heart sound recordings: The PhysioNet/Computing in Cardiology Challenge 2016, ” in *Computing in Cardiology Conference (CinC)*, 2016, 2016, pp. 609-612: IEEE.

- [27] D. B. Springer, L. Tarassenko, and G. D. Clifford, "Logistic regression-hsmm-based heart sound segmentation," *IEEE Transactions on Biomedical Engineering*, vol. 63, no. 4, pp. 822-832, 2016.
- [28] M. Nabih-Ali, E.-S. A. El-Dahshan, and A. S. Yahia, "Heart diseases diagnosis using intelligent algorithm based on PCG signal analysis," *Circuits Syst*, vol. 8, no. 7, pp. 184-190, 2017.
- [29] Tian, G., Lian, C., Xu, B., Zang, J., Zhang, Z., & Xue, C. (2023). Classification of Phonocardiogram Based on Multi-View Deep Network. *Neural Processing Letters*, 55(2023), 3655–3670.
- [30] S. Ismail, B. Ismail, I. Siddiqi, and U. Akram, "PCG classification through spectrogram using transfer learning," *Biomedical Signal Processing and Control*, vol. 79, p. 104075, 2023.
- [31] S.L. Oh, V. Jahmunah, C.P. Ooi, R.-S. Tan, E.J. Ciaccio, T. Yamakawa, M. Tanabe, M. Kobayashi, U.R. Acharya, Classification of heart sound signals using a novel deep WaveNet model, *Comput. Methods Programs Biomed.* 196 (2020) 105604.
- [32] C. Liu, D. Springer, and G. D. Clifford, "Performance of an open-source heart sound segmentation algorithm on eight independent databases," *Physiological measurement*, vol. 38, no. 8, p. 1730, 2017.
- [33] B. Boashash, *Time-frequency signal analysis and processing: a comprehensive reference*. Academic Press, 2015.
- [34] B. Boashash, G. Azemi, and J. M. O'Toole, "Timefrequency processing of nonstationary signals: Advanced TFD design to aid diagnosis with highlights from medical applications," *IEEE Signal Processing Magazine*, vol. 30, no. 6, pp. 108-119, 2013.
- [35] W.-C. Kao and C.-C. Wei, "Automatic phonocardiograph signal analysis for detecting heart valve disorders," *Expert Systems with Applications*, vol. 38, no. 6, pp. 6458-6468, 2011.
- [36] C. Potes, S. Parvaneh, A. Rahman, and B. Conroy, "Ensemble of feature-based and deep learning-based classifiers for detection of abnormal heart sounds," in *Computing in Cardiology Conference (CinC)*, 2016, 2016, pp. 621-624: IEEE.
- [37] [One Hot Encoding in Machine Learning - GeeksforGeeks](#)
- [38] [Classification of Heart Sound Recordings: The PhysioNet/Computing in Cardiology Challenge 2016 v1.0.0](#)
- [39] C. Liu et al., "An open access database for the evaluation of heart sound algorithms," *Physiological Measurement*, vol. 37, no. 12, p. 2181, 2016.
- [40] [Did You Know? THI's Heart Sounds Laboratory | The Texas Heart Institute](#)
- [41] [Classifying Heart Sounds Challenge \(peterjbentley.com\)](#)
- [42] [Heart Sound & Murmur Library | Open Michigan \(umich.edu\)](#)
- [43] [How to Normalize Data Using scikit-learn in Python | DigitalOcean](#)

- [44] B. Boashash, G. Azemi, and N. A. Khan, "Principles of time–frequency feature extraction for change detection in non-stationary signals: Applications to newborn EEG abnormality detection, " *Pattern Recognition*, vol. 48, no. 3, pp. 616-627, 2015.
- [45] J. J. G. Ortiz, C. P. Phoo, and J. Wiens, "Heart sound classification based on temporal alignment techniques, " in *Computing in Cardiology Conference (CinC)*, 2016, 2016, pp. 589-592 :IEEE.
- [46] N. Verbiest, C. Cornelis, and R. Jensen, "Fuzzy rough positive region based nearest neighbour classification, " in *Fuzzy Systems (FUZZ-IEEE)*, 2012 IEEE International Conference on, 2012, pp. 1-7: IEEE.
- [47] J. M. Keller, M. R. Gray, and J. A. Givens, "A fuzzy knearest neighbor algorithm, " *IEEE transactions on systems, man, and cybernetics*, no. 4, pp. 580-585, 1985.